

Exercício 5

Matheus Arataque Uema - 10276949

Herlisson Maciel Bezerra - 10224760

Dhyogo Nunes Costa - 13096109

SCC5809 - Redes Neurais e Aprendizado Profundo

Resumo

Este relatório apresenta a aplicação do modelo de uma rede adversária generativa (GAN) utilizando redes convolucionais (CNNs) nos módulos com função de ativação *TANH* no modelo gerador e uma camada densa de um neurônio para o modelo discriminador. A rede neural foi treinada a partir de um conjunto de dados MNIST com imagens de dígitos manuscritos, e foi avaliada pela técnica de entropia cruzada. Os resultados indicam a eficácia do modelo na geração de imagens considerando o ruído.

1 Introdução

Neste relatório, será discutido o desenvolvimento e treinamento de uma Rede Generativa Adversarial (GAN) utilizando redes neurais convolucionais (CNNs). O objetivo é gerar imagens a partir de ruídos utilizando o conjunto de dados MNIST, que contém imagens de dígitos manuscritos.

2 Metodologia

2.1 Dados

O conjunto de dados utilizado é o MNIST, que contém imagens de dígitos manuscritos de tamanho 28×28 . As imagens foram normalizadas para o intervalo $[-1, 1]$ para adequar-se à função de ativação *tanh* usada no gerador. A normalização foi realizada da seguinte forma:

$$\text{Imagem Normalizada} = \frac{\text{Imagem Original} - 127.5}{127.5}$$

2.2 Implementação

Duas redes principais compõem a GAN:

- **Modelo Gerador:** Recebe um vetor de ruído aleatório como entrada e gera uma imagem a partir dele.
- **Modelo Discriminador:** Classifica as imagens geradas como reais ou falsas.

O **modelo gerador** é baseado em camadas transpostas convolucionais (Conv2DTranspose) e é responsável por transformar uma seed aleatória em uma imagem de 28×28 . Sua arquitetura pode ser vista a seguir:

- Camada densa de saída $7 \times 7 \times 256$, que utiliza Batch Normalization e Leaky ReLU.
- Camadas Conv2DTranspose para aumentar a dimensão da imagem até $28 \times 28 \times 1$.
- Função de ativação **tanh** na camada de saída.

Já, o **modelo discriminador** classifica as imagens geradas. Ele é composto por camadas convolucionais que processam as imagens e retorna uma previsão binária a partir da seguinte arquitetura:

- Duas camadas convolucionais com 64 e 128 filtros, respectivamente, com ativação Leaky ReLU e dropout de 30%.
- A camada final é uma densa com um único neurônio para classificação.

Como função de custo, foi utilizada **entropia cruzada** para quantificar a performance dos modelos gerador e discriminador. No gerador, ela penaliza o modelo quando o discriminador classifica corretamente as imagens falsas, e no discriminador ela mede o desempenho na classificação de imagens reais e geradas.

Para o treinamento, foram utilizadas 50 épocas. A cada época, o gerador cria novas imagens baseadas em uma seed aleatória, e o discriminador tenta classificar essas imagens como reais ou falsas. Durante cada iteração:

1. O gerador recebe um vetor de ruído e gera imagens, como exemplificado pela Figura 1.
2. O discriminador classifica tanto as imagens reais quanto as geradas.
3. A função de custo é calculada para ambos os modelos e os gradientes são aplicados para atualização dos pesos.

A implementação do código pode ser visualizada no repositório criado no *GitHub*¹

¹Repositório do Código Disponível em: <https://github.com/MatheusUema/neural-networks-study>. Acesso em: 15 de out. de 2024.




Figura 1: Imagem gerada pelo modelo durante o treinamento, na época 42

3 Resultados

Durante o treinamento, foi possível observar uma melhoria contínua na qualidade das imagens geradas conforme o gerador melhorava sua capacidade de enganar o discriminador. A cada época, as imagens geradas foram salvas para serem utilizadas na criação de um GIF que demonstra a evolução do processo de treinamento.

O tempo de execução para cada época foi registrado e analisado, mostrando que o tempo médio por época foi de aproximadamente 12 segundos.

4 Conclusão

Este exercício demonstrou a eficácia das Redes Generativas Adversariais em gerar imagens a partir de ruído usando CNNs. O modelo foi capaz de produzir imagens coerentes com o conjunto de dados MNIST após o treinamento. No entanto, a qualidade final das imagens geradas pode variar dependendo da arquitetura do modelo e do número de épocas utilizadas no treinamento.