

Exercício 6

Matheus Arataque Uema - 10276949

Herlisson Maciel Bezerra - 10224760

Dhyogo Nunes Costa - 13096109

SCC5809 - Redes Neurais e Aprendizado Profundo

Resumo

Este relatório apresenta a avaliação da acurácia de modelos de redes convolucionais com três diferentes otimizadores: *Adagrad*, *RMSprop* e *Adam*. Para cada modelo foram utilizadas três camadas convolucionais com e sem *dropout*. A rede foi treinada a partir da base de imagens CIFAR-10 que contém 60.000 imagens de 10 classes diferentes, e foi avaliada a acurácia. Os resultados indicam uma eficácia superior do otimizador *Adam* em relação aos demais otimizadores.

1 Introdução

Neste relatório, será aprofundado o conceito de otimizadores utilizados nas redes neurais convolucionais. O objetivo é treinar na base de imagens a partir de três diferentes otimizadores - *Adagrad*, *RMSprop* e *Adam* - para então avaliar sua acurácia.

O otimizador *Adagrad* (*Adaptive Gradient Algorithm*) ajusta a taxa de aprendizado individualmente para cada parâmetro, de forma que parâmetros frequentemente atualizados possuem uma taxa de aprendizado reduzida se comparada àqueles raramente atualizados. Isso pode ser vantajoso devido a não ser necessário ajustar manualmente as taxas, no entanto a taxa de aprendizado pode diminuir continuamente fazendo com o que o modelo pare antes de atingir um ótimo global.

Devido a esse problema, o *RMSprop* (*Root Mean Square Propagation*) surgiu como uma melhoria em relação ao primeiro otimizador. Ele utiliza a média móvel dos quadrados dos gradientes para normalizar os parâmetros, evitando assim que a taxa de aprendizado diminua continuamente. Apesar disso, é necessário um parâmetro adicional denominado fator de decaimento, o qual pode exigir mais experimentação.

Com relação ao último otimizador, o *Adam* (*Adaptive Moment Estimation*) usa estimativas da média e da variância dos gradientes, possibilitando uma adaptação dinâmica das taxas de aprendizado para cada parâmetro. Devido a isso, ele permite uma convergência mais rápida e é efetivo em problemas com

grandes conjuntos de dados. No entanto, pode ser mais sensível à escolha dos hiperparâmetros (como a taxa de decaimento).

Por fim, o *dropout* é uma técnica que previne o *overfitting* desativando aleatoriamente uma fração dos neurônios em cada iteração. Devido a isso, o tempo de treinamento pode aumentar, e deve ser usado com cautela para não prejudicar o aprendizado.

Por conta disso, espera-se que o otimizador *Adam* possua uma acurácia melhor ao fim dos testes e que os modelos com *dropout* levem mais iterações para convergirem.

2 Metodologia

2.1 Dados

O conjunto de dados utilizado é o CIFAR-10, que contém 60.000 imagens coloridas em 10 classes, com 6.000 imagens em cada classe. O conjunto de dados é dividido em 50.000 imagens de treinamento e 10.000 imagens de teste. As classes são mutuamente exclusivas e não há sobreposição entre elas.

As imagens foram normalizadas para o intervalo $[-1, 1]$ da seguinte forma:

$$\text{Imagem Normalizada} = \frac{\text{Imagem Original}}{255.0}$$

2.2 Implementação

A rede neural foi implementada com três camadas comuns convolucionais - uma pilha de camadas *Conv2D* e *MaxPooling2D* - que foram configuradas para processar entradas de forma (32, 32, 3) - formato das imagens CIFAR. Ao fim, a saída foi achatada para 1D e então foram adicionadas mais camadas densas no topo. Aqui também é aplicado o *dropout*, se necessário, e por fim foi utilizada uma camada *Dense* de 10 saídas, visto que o CIFAR contém 10 classes de saída.s.

Para o treinamento, foram utilizadas 10 épocas, e para cada uma delas registrou-se as medidas de acurácia da base de treino e de teste. Ao fim, foi mensurado a acurácia para base de teste.

A implementação do código pode ser visualizada no repositório criado no *GitHub*¹

3 Resultados

A seguir, estão apresentadas as figuras da medida de acurácia por época. É possível que as Figuras 5 e 6, referentes aos modelos *Adam*, possuem uma acurácia com maior taxa de crescimento a cada época se comparada aos demais modelos.

¹Repositório do Código Disponível em: <https://github.com/MatheusUema/neural-networks-study>. Acesso em: 22 de out. de 2024.




Figura 1: Modelo *Adagrad*:
acurácia por época.




Figura 2: Modelo *Adagrad + Dropout*:
acurácia por época.




Figura 3: Modelo *RMSprop*:
acurácia por época.




Figura 4: Modelo *RMSprop + Dropout*:
acurácia por época.




Figura 5: Modelo *Adam*:
acurácia por época.




Figura 6: Modelo *Adam + Dropout*:
acurácia por época.

Por fim, as acurácias obtidas para o modelo completamente treinado podem ser vistas na Tabela 1 abaixo. Vê-se que, como esperado, os modelos com *dropout* possuem uma acurácia menor que seus respectivos modelos sem a técnica de regularização devido ao fato de que seriam necessárias mais épocas para alcançar o mesmo desempenho. Somado a isso, os resultados superiores das redes neurais com otimizadores *Adam* também eram esperados, confirmando o seu desempenho superior para essa base de dados.

Modelo	Acurácia
<i>Adagrad</i>	43.27%
<i>Adagrad + Dropout</i>	39.78%
<i>RMSprop</i>	68.36%
<i>RMSprop + Dropout</i>	58.92%
<i>Adam</i>	69.85%
<i>Adam + Dropout</i>	69.51%

Tabela 1: Acurácia obtida para cada modelo

4 Conclusão

Este exercício demonstrou a eficácia das redes CNNs a partir de diferentes otimizadores. Os modelos *RMSprop* e *Adam* no geral apresentaram resultados satisfatórios para essa base de imagens, no entanto o modelo *Adagrad* deixou a desejar. Por fim, acredita-se que com *dropout* seriam necessárias mais iterações, o que poderia prejudicar as taxas de aprendizados do *Adagrad* e do *RMSprop*.